TUGAS ANALISIS 1: DEKONSTRUKSI ARSITEKTUR DAN KALKULASI ATTENTION

Nama: Nur Azifah Diah Mustapa

Nim: 60900124124

Kelas: E

1. Dekonstruksi Matematis Scaled Dot-Product Attention

Scaled Dot-Product Attention merupakan mekanisme pada Transformer yang menghitung tingkat perhatian antartoken menggunakan tiga komponen utama, yaitu Query (Q), Key (K), dan Value (V). Perhitungan bobot perhatian dilakukan dengan mengalikan matriks Q dengan transpose K, membagi hasilnya dengan akar dimensi Key, kemudian menerapkan fungsi Softmax.

Pada contoh ini digunakan tiga token, yaitu “Saya”, “Belajar”, dan “AI”, dengan dimensi fitur kunci d_k = 2. Matriks Q dan K ditentukan sebagai berikut:

Q = [[1, 0], [0, 1], [1, 1]]

K = [[1, 0], [0, 1], [1, 1]]

Transpose matriks K adalah:

K^T = [[1, 0, 1], [0, 1, 1]]

Perkalian matriks Q dengan K^T menghasilkan:

QK^T = [[1, 0, 1], [0, 1, 1], [1, 1, 2]]

Selanjutnya, hasil perkalian dibagi dengan $\sqrt{d_k} = \sqrt{2} \approx 1{,}4142$ untuk menstabilkan nilai skor perhatian.

$S = QK^T / \sqrt{2}$

S = [[0,7071, 0, 0,7071], [0, 0,7071, 0,7071], [0,7071, 0,7071, 1,4142]]

Fungsi Softmax digunakan untuk mengubah skor pada setiap baris menjadi bobot probabilitas dengan rumus:

$\text{Softmax}(x_i) = \exp(x_i) / \Sigma \exp(x_j)$

Sebagai contoh, untuk baris pertama, nilai skornya adalah [0,7071; 0; 0,7071]. Setelah fungsi Softmax diterapkan, diperoleh bobot perhatian sekitar [0,4011; 0,1978; 0,4011].

Matriks bobot perhatian setelah Softmax adalah sebagai berikut:

Query / Key	**Saya**	**Belajar**	**AI**
Saya	0,4011	0,1978	0,4011
Belajar	0,1978	0,4011	0,4011
AI	0,2483	0,2483	0,5035

Berdasarkan hasil tersebut, Query "AI" memberikan bobot perhatian tertinggi kepada Key "AI", yaitu sekitar 0,5035. Hal ini menunjukkan bahwa skor kecocokan antara token "AI" dengan dirinya sendiri lebih tinggi dibandingkan dua token lainnya pada contoh matriks tersebut. Selanjutnya, bobot perhatian dapat digunakan untuk menggabungkan informasi dari matriks Value (V) sehingga menghasilkan representasi token yang mempertimbangkan konteks.

2. Analisis Arsitektur Encoder dan Decoder

BERT menggunakan arsitektur utama Encoder, sedangkan GPT menggunakan arsitektur utama Decoder. Perbedaan tersebut berkaitan dengan tujuan pemrosesan teks dan cara setiap arsitektur memanfaatkan konteks.

Aspek	**Encoder — BERT**	**Decoder — GPT**
Tujuan	Memahami teks dan membentuk representasi kontekstual.	Menghasilkan teks secara bertahap dengan memprediksi token berikutnya.
Self-Attention	Bersifat bidirectional sehingga token dapat memperhatikan token di sebelah kiri dan kanan dalam input.	Menggunakan causal atau masked attention sehingga token hanya dapat memperhatikan token sebelumnya dan dirinya sendiri.
Kelebihan	Cocok untuk klasifikasi teks, pemahaman konteks, dan ekstraksi informasi.	Cocok untuk generasi teks, melanjutkan kalimat, dan menghasilkan respons.
Kelemahan	Tidak dirancang secara langsung untuk generasi autoregresif token demi token.	Kesalahan prediksi suatu token dapat memengaruhi token berikutnya, dan model tidak dapat melihat token masa depan ketika memprediksi token saat ini.

Komponen Penting dalam Arsitektur Transformer

Masked Attention (Causal Masking)

Causal Masking digunakan pada Decoder autoregresif untuk mencegah model melihat token masa depan ketika memprediksi token berikutnya. Posisi yang dilarang diberi skor sangat negatif sebelum Softmax sehingga bobot perhatiannya menjadi nol atau mendekati nol. Dengan demikian, proses generasi berlangsung secara berurutan.

Cross-Attention

Cross-Attention digunakan pada arsitektur Encoder–Decoder. Dalam mekanisme ini, Query berasal dari keluaran Decoder, sedangkan Key dan Value berasal dari keluaran Encoder. Mekanisme tersebut memungkinkan Decoder menggunakan informasi dari teks sumber. Cross-Attention berbeda dari Causal Self-Attention dan bukan komponen wajib pada setiap arsitektur GPT.

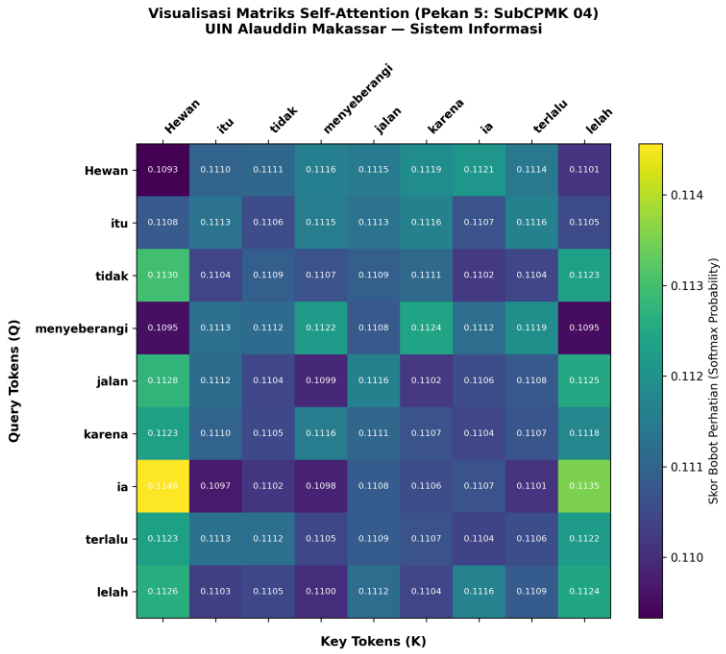
Residual Connection

Residual Connection merupakan mekanisme yang menambahkan masukan suatu sublapisan ke keluarannya. Mekanisme ini membantu mempertahankan informasi dan mendukung aliran gradien selama proses pelatihan jaringan yang memiliki banyak lapisan.

Berdasarkan perbandingan tersebut, Encoder lebih sesuai untuk membangun representasi teks berdasarkan konteks dua arah, sedangkan Decoder kausal lebih sesuai untuk menghasilkan urutan teks secara autoregresif.

3. Eksperimen Kode dan Analisis Heatmap

Eksperimen dilakukan menggunakan Python 3.11.9 dengan pustaka NumPy dan Matplotlib. Kalimat uji yang digunakan adalah “Hewan itu tidak menyeberangi jalan karena ia terlalu lelah”, yang terdiri dari sembilan token. Program menghasilkan matriks bobot Self-Attention dan menyimpannya dalam file attention_heatmap_pekan_05.png.



Gambar tersebut merupakan visualisasi distribusi bobot perhatian antartoken. Sumbu vertikal menunjukkan Query Tokens (Q), yaitu token yang memberikan perhatian, sedangkan sumbu horizontal menunjukkan Key Tokens (K), yaitu token yang diperhatikan. Setiap sel menunjukkan bobot perhatian hasil Softmax untuk pasangan Query dan Key.

Berdasarkan visualisasi, pada baris Query “ia”, kolom “Hewan” terlihat memiliki bobot perhatian relatif tinggi. Kolom “lelah” juga tampak menunjukkan bobot yang relatif tinggi. Hal tersebut dapat diamati melalui perbedaan warna pada heatmap. Namun, angka pada gambar dibulatkan menjadi dua angka desimal sehingga nilai yang lebih presisi diperlukan untuk memastikan urutan bobot tertinggi secara pasti.

Perlu diperhatikan bahwa skrip praktikum menggunakan vektor acak dan bias buatan dalam demonstrasi perhitungannya. Oleh karena itu, heatmap tersebut menunjukkan cara kerja perhitungan Self-Attention pada implementasi yang digunakan, bukan bukti langsung bahwa model bahasa terlatih telah memahami makna kalimat atau menyelesaikan hubungan kata ganti secara nyata.

Kesimpulan

Scaled Dot-Product Attention menghitung skor perhatian melalui perkalian QK^T, membagi hasilnya dengan √d_k, kemudian menerapkan Softmax untuk menghasilkan bobot perhatian. Bobot tersebut digunakan untuk menggabungkan informasi dari Value (V) dan membentuk representasi kontekstual.

Analisis arsitektur menunjukkan bahwa Encoder seperti BERT berorientasi pada pemahaman konteks dua arah, sedangkan Decoder seperti GPT menggunakan causal masking untuk mendukung generasi teks secara autoregresif. Eksperimen heatmap membantu memperlihatkan distribusi bobot perhatian antarkata dan memberikan gambaran mengenai mekanisme Self-Attention, dengan tetap memperhatikan keterbatasan simulasi yang digunakan.

Link Github
https://github.com/nurazifahdiahm-cloud/tugas-analisis-1-transformer